Автовекторизация в LLVM

Артём Скребков

- Инженер-программист в области глубокого обучения (Deep Learning Software Engineer)
- Закончил ННГУ им. Лобачевского, ИТММ, Прикладная математика и информатика в 2017
- В Интел с 2016
- Текущий проект
  - VPUX Plugin for OpenVINO
- Прошлые проекты
  - MYRIAD and HDDL plugins for OpenVINO
  - Реализация OpenVX API for DSP processor
- Профессиональные интересы
  - Глубокое обучение, оптимизация под VPU (vision processor unit), функциональное программирование, C++, *Rust, Clojure*
- e-mail: skrebkov.art@gmail.com

План

- Введение. SIMD
- Автовекторизация в LLVM
  - Как?
  - Настройки векторизации
  - Диагностика
- Как писать автовекторизуемый код
- Постановка задачи

Введение. SIMD

SIMD – Single Instruction Multiple Data

- SIMD
  - Одна и та же операция работает паралельно над множеством однородных данных
  - Количество данных в векторе не влияет на время исполнения
- Векторные расширения
  - MMX – 64 бита
  - SSE, SSE2, SSE3, SSE4 – 128 бит
  - AVX, AVX2 – 256 бит
  - AVX512 – 512 бит

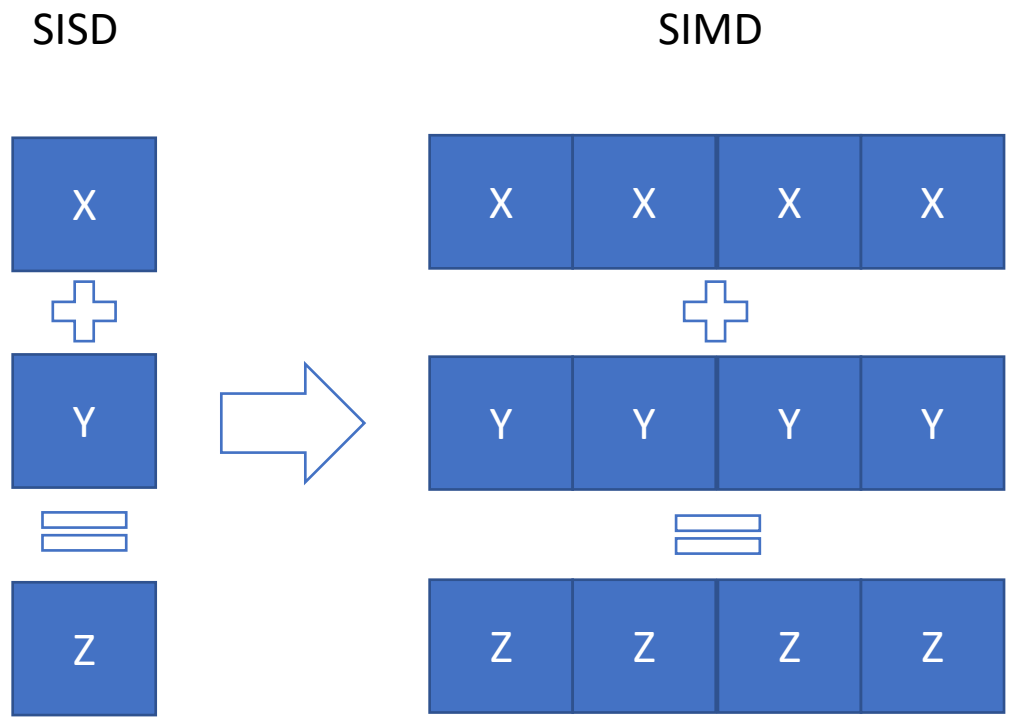

Применение

- SIMD позволяет добиться прироста производительности в задачах, где требуется обработка большового количества однородных данных
  - 3D графика
  - Физическое/математическое моделирование
  - Обратка изображений/видео
  - Кодирование/декодирование видео

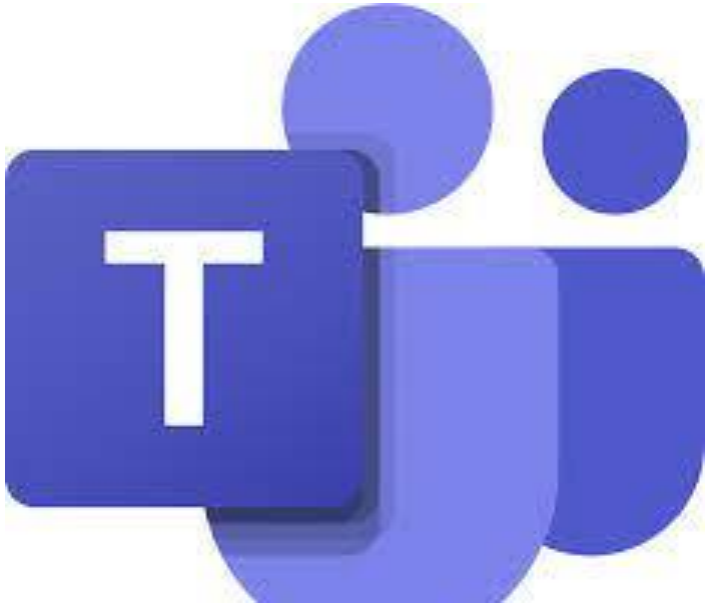

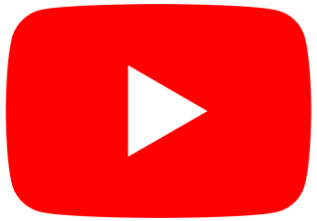

Как использовать SIMD

- Ассемблерные вставки

```
vmovdqu ymm0, ymmword ptr [4*rdx + y]
vpaddd ymm0, ymm0, ymmword ptr [4*rdx + x]
vmovdqu ymmword ptr [4*rdx + y], ymm0
```

- Сложен в разработке и поддержке
- Нет переносимости
  - Зависимость на платформу и компилятор

Как использовать SIMD

- Интринсики (intrinsics)
  - Функции, которые компилятор заменяет на соотвествующие инструкции

```
int64_t cnt = 0;
auto sseVal = _mm_set1_epi16(VAL);
for (int i = 0; i < ARR_SIZE; i += 8) {
  auto sseArr = _mm_set_epi16(arr[i + 7], arr[i + 6],…, arr[i + 1], arr[i]);
  cnt += _popcnt32(_mm_movemask_epi8(_mm_cmpeq_epi16(sseVal, sseArr)));
}
```

- Проще чем уровень ассемблера
  - Но всё ещё сложен для разработки и поддержки
- Всё ещё нет переносимости
  - Зависимость на процессор

Как использовать SIMD

- Механизм автовекторизации в компиляторе
  - clang -O3 …
- Прост в поддержке и разработке
  - Сравнительно с предыдущими способами
- Портируемость

Раскрутка цикла (loop unrolling)

- Техника оптимизации, состоящая в искусственном увеличении количества инструкций, исполняемых в течение одной итерации цикла
- Потенциально
  - Параллелизм инструкции
  - Большая нагрузка кэша и регистров

```
#pragma clang loop unroll_count(2)
for (int i = 0; i < 64; i++) {
  data[i] = input[i] * other[i];
}
```

Превращается

```
for (int i = 0; i < 64; i +=2) {
  data[i] = input[i] * other[i];
  data[i+1] = input[i+1] * other[i+1];
}
```

Loop interleaving

- Особый случай раскрутки цикла применяемый при векторизации
- Цель та же самая как в случае раскрутки цикла

```
#pragma clang loop interleave_count(2) vectorize_width(2)
for (int i = 0; i < 64; i++) {
  data[i] = input[i] * other[i];
}
```

Превращается

```
for (int i = 0; i < 64; i +=4) {
  data[i..(i+1)] = input[i..(i+1)] * other[i..(i+1)];
  data[(i+2)..(i+3)] = input[(i+2)..(i+3)] * other[(i+2)..(i+3)];
}
```

Автовекторизация в LLVM

Как включить?

- Авто-векторизация включена по-умолчанию (-O2, -Os, -O3)
- Может быть выключена с помощью -fno-vectorize

Настройки

- Параметры векторизации
  - Ширина вектора (-force-vector-width)
    - $ clang -force-vector-width=8 ...
  - Значение раскрутки цикла (-force-vector-interleave)
    - $ clang -force-vector-interleave=2
- Если значение не указаны явно компилятор подбирает их автоматически

Отладка автовекторизации

- Во время шага векторизации компилятор генерирует векторизационный отчёт
- Информация из отчёт может быть получена с помощью опции
  - -Rpass=loop-vectorize сообщит о векторизованных циклах
  - -Rpass-missed=loop-vectorize сообщит о невекторизованных циклах
  - -Rpass-analysis=loop-vectorize покажет причины почему цикл не был векторизован

```
example.cpp:8:5: remark: loop not vectorized: loop control flow is not understood by vectorizer [-Rpass-analysis=loop-vectorize]
for (int i = 0; i < len; i++) {
^
example.cpp:8:5: remark: loop not vectorized: loop control flow is not understood by vectorizer [-Rpass-analysis=loop-vectorize]
example.cpp:8:5: remark: loop not vectorized: loop control flow is not understood by analyzer [-Rpass-analysis=loop-vectorize]
example.cpp:8:5: remark: loop not vectorized [-Rpass-missed=loop-vectorize]
example.cpp:14:5: remark: vectorized loop (vectorization width: 8, interleaved count: 4) [-Rpass=loop-vectorize]
for (int i = 0; i < m; i++) {
^
```

Как помочь компилятору?

Общие рекомендации

- Цикл вероятнее может быть векторизован если выполненены следущие условия
  - Количество итераций должно быть известно до исполнения цикла
    - Отсутвие операторов break и continue
  - Векторизуется только самый вложенный цикл (**innermost loop**)
  - Нет вызов функций
    - Встраиваемые функции (**inline functions**) без побочных эффектов разрешены
    - Базовые математические функии (pow(), sqrt(), exp(), …) разрешены
  - Не ветвлящийся поток управления (**single control flow**)
    - Отсутсвие оператора switch

Невекторизуемые циклы

- Оператор break внутри цикла

```
for (int i = 0; i < len; i++)
{
  if (x[i] == 42) break;
  y[i] += x[i];
}
```

- Goldbolt

```
•example.cpp:7:5: remark: loop not vectorized: loop control flow is not understood by vectorizer [-Rpass-analysis=loop-vectorize]
for (int i = 0; i < len; i++) {
^
example.cpp:7:5: remark: loop not vectorized: loop control flow is not understood by vectorizer [-Rpass-analysis=loop-vectorize]
example.cpp:7:5: remark: loop not vectorized: loop control flow is not understood by analyzer [-Rpass-analysis=loop-vectorize]
example.cpp:7:5: remark: loop not vectorized [-Rpass-missed=loop-vectorize]
```

Невекторизуемые циклы

- Второй цикл теперь векторизуемый

```
int m = len;
for (int i = 0; i < len; i++) {
  if (x[i] == 42) {
    m = i;
    break;
  }
}
for (int i = 0; i < m; i++) {
  y[i] += x[i];
}
```

- Goldbolt

```
example.cpp:8:5: remark: loop not vectorized: loop control flow is not understood by vectorizer [-Rpass-analysis=loop-vectorize]
for (int i = 0; i < len; i++) {
^
example.cpp:8:5: remark: loop not vectorized: loop control flow is not understood by vectorizer [-Rpass-analysis=loop-vectorize]
example.cpp:8:5: remark: loop not vectorized: loop control flow is not understood by analyzer [-Rpass-analysis=loop-vectorize]
example.cpp:8:5: remark: loop not vectorized [-Rpass-missed=loop-vectorize]
example.cpp:14:5: remark: vectorized loop (vectorization width: 8, interleaved count: 4) [-Rpass=loop-vectorize]
for (int i = 0; i < m; i++) {
^
```

Невекторизуемые циклы

- Проверка внешнего состония “errno”

```
for (int i = 0; i < len; i++)
{
    x[i] = exp(y[i]);
    if (errno == ERANGE) {
        x[i] = 0;
    }
}
```

- Goldbolt

example.cpp:10:16: remark: loop not vectorized: call instruction cannot be vectorized [-Rpass-analysis=loop-vectorize]
x[i] = exp(y[i]);
^
example.cpp:9:5: remark: loop not vectorized: instruction cannot be vectorized [-Rpass-analysis=loop-vectorize]
for (int i = 0; i < len; i++) {
^
example.cpp:9:5: remark: loop not vectorized [-Rpass-missed=loop-vectorize]

Невекторизуемые циклы

- Второй цикл теперь векторизуемый (-fno-math-errno)

```
for (int i = 0; i < len; i++)
{
    x[i] = exp(y[i]);
}
```

- Compiler Explorer

example.cpp:9:5: remark: the cost-model indicates that interleaving is not beneficial [-Rpass-analysis=loop-vectorize]
for (int i = 0; i < len; i++) {
^
example.cpp:9:5: remark: vectorized loop (vectorization width: 4, interleaved count: 1) [-Rpass=loop-vectorize]

Невекторизуемые циклы

- Оператор switch внутри цикла

```
for (int i = 0; i < len; i++)
{
   switch(x[i]) {
   case 0: x[i] = i*2; break;
   case 1: x[i] = i;   break;
   default: x[i] = 0;
   }
}
```

- Goldbolt

```
example.cpp:7:9: remark: loop not vectorized: loop contains a switch statement [-Rpass-analysis=loop-vectorize]
switch (x[i]) {
^
example.cpp:6:5: remark: loop not vectorized [-Rpass-missed=loop-vectorize]
for (int i = 0; i < len; i++) {
^
```

Невекторизуемые циклы

- Количество итераций неизвестно до исполнения

```
while (*p != 0) {
   *q++ = *p++;
}
```

- Goldbolt

```
xample.cpp:9:5: remark: loop not vectorized: value that could not be identified as reduction is used outside the loop [-Rpass-analysis=loop-vectorize]
while (*p != 0) {
^
example.cpp:9:5: remark: loop not vectorized: could not determine number of loop iterations [-Rpass-analysis=loop-vectorize]
example.cpp:9:5: remark: loop not vectorized [-Rpass-missed=loop-vectorize]
```

Постановка задачи

Постановка задачи

- Требуется провести анализ заданнового цикла в форме отчёта
- Подробная инструкция
  - https://github.com/ArtemSkrebkov/autovectorization-practise/blob/main/README.md
- Кратко что нужно сделать:
  1. Определить конфигурацию тестовой платформы
  2. Исследовать цикл
     1. Получить LLVM IR в следующих конфигурация:
        1. Без векторизации и раскрутки
        2. Без векторизации, с раскруткой
        3. С векторизацией, без раскрутки
        4. С векторизацией и раскруткой
     2. Провести измерения времени исполнения цикла в тех же самых конфигурациях
  3. Проанализировать полученные результаты

Пререквезиты

- Инструменты
  - clang-11, git
- Репозиторий
  - https://github.com/ArtemSkrebkov/autovectorization-practise.git

Цель практики

- Проанализировать LLVM IR в различных конфигурациях
- Посмотреть на что способен компилятор

Определение конфигурации

- Поиск в интернете
  - Информация об процессорах Intel может быть найдена здесь
  - Информация об процессорах AMD может быть найдена, например, здесь
- Windows
  - CPU-Z
- Linux

```
$ lscpu
```

- Пример конфигурации
  - Intel® Core™ i5-8350U Processor
  - Instruction Set Extensions Intel® SSE4.1, Intel® SSE4.2, Intel® AVX2

Исследуемый цикл

- Пример

```
void run(){
   for (int i=0; i < N; i++) {
      r[i] = a[i] + b[i];
   }
}
```

Как получить LLVM IR для заданной функции

- Генерируем llvm-байт код
  - clang -I./loops/vectorizable/ -DINCLUDE_TEST=\"testN.hpp\" test.cpp **-emit-llvm** -c -o testN.bc
- Излекаем llvm-байт код интересующей нас функции
  - llvm-extract **-func=?run@testFunc@@QEAAXXZ** test5.bc -o run-fn.bc
- Дизассемблирует llvm-байт код в текстовое представление
  - llvm-dis run-fn.bc -o run-fn.ll
- run-fn.ll содержит текстовое представление LLVM IR

Скалярный vs “раскрученный” код

Параметры: -O3 –fno-vectorize –fno-unroll-loops

for.body:

%0 = load float, float* %arrayidx, align 4, !tbaa !3

%1 = load float, float* %arrayidx3, align 4, !tbaa !3

%add = fadd float %0, %1

store float %add, float* %arrayidx5, align 4, !tbaa !3

- *В целях улучшения читаемости вспомогательные инструкции были удалены из листингов*

Параметры: -O3 –fno-vectorize

for.body:

%0 = load float, float* %arrayidx, align 4, !tbaa !3

%1 = load float, float* %arrayidx3, align 4, !tbaa !3

%add = fadd float %0, %1

store float %add, float* %arrayidx5, align 4, !tbaa !3

%2 = load float, float* %arrayidx.1, align 4, !tbaa !3

%3 = load float, float* %arrayidx3.1, align 4, !tbaa !3

%add.1 = fadd float %2, %3

store float %add.1, float* %arrayidx5.1, align 4, !tbaa !3

%4 = load float, float* %arrayidx.2, align 4, !tbaa !3

%5 = load float, float* %arrayidx3.2, align 4, !tbaa !3

%add.2 = fadd float %4, %5

store float %add.2, float* %arrayidx5.2, align 4, !tbaa !3

%6 = load float, float* %arrayidx.3, align 4, !tbaa !3

%7 = load float, float* %arrayidx3.3, align 4, !tbaa !3

%add.3 = fadd float %6, %7

store float %add.3, float* %arrayidx5.3, align 4, !tbaa !3

В 4 раза больше инструкции за 1 итерацию

Скалярный vs векторизованный код

В 4 раза больше данных за 1 итерацию

Параметры: -O3 –fno-vectorize –fno-unroll-loops

for.body:

%0 = load float, float* %arrayidx, align 4, !tbaa !3

%1 = load float, float* %arrayidx3, align 4, !tbaa !3

%add = fadd float %0, %1

store float %add, float* %arrayidx5, align 4, !tbaa !3

- *В целях улучшения читаемости вспомогательные инструкции были удалены из листингов*

Параметры: -O3 –fno-unroll-loops

vector.body:

%0 = getelementptr inbounds %struct.testFunc, %struct.testFunc* %this, i64 0, i32 0, i64 %index

%1 = bitcast float* %0 to <4 x float>*

%wide.load = load <4 x float>, <4 x float>* %1, align 4, !tbaa !3

%2 = getelementptr inbounds %struct.testFunc, %struct.testFunc* %this, i64 0, i32 1, i64 %index

%3 = bitcast float* %2 to <4 x float>*

%wide.load12 = load <4 x float>, <4 x float>* %3, align 4, !tbaa !3

%4 = fadd <4 x float> %wide.load, %wide.load12

%5 = getelementptr inbounds %struct.testFunc, %struct.testFunc* %this, i64 0, i32 2, i64 %index

%6 = bitcast float* %5 to <4 x float>*

store <4 x float> %4, <4 x float>* %6, align 4, !tbaa !3

Скалярный vs векторизованный и “раскрученный” код

В 4 раза больше данных, в 4 раза больше инструкций за 1 итерацию

Параметры: -O3 –fno-vectorize –fno-unroll-loops

```
for.body:
%0 = load float, float* %arrayidx, align 4, !tbaa !3
%1 = load float, float* %arrayidx3, align 4, !tbaa !3
%add = fadd float %0, %1
store float %add, float* %arrayidx5, align 4, !tbaa !3
```

Параметры: -O3

```
vector.body:
%index = phi i64 [ %index.next.1, %vector.body ], [ 0, %entry ]
  %3 = getelementptr inbounds float, float* %0, i64 %index
  %4 = bitcast float* %3 to <4 x float>*
  %wide.load = load <4 x float>, <4 x float>* %4, align 4, !tbaa !13, !alias.scope !15
  %5 = getelementptr inbounds float, float* %3, i64 4
  %6 = bitcast float* %5 to <4 x float>*
  %wide.load24 = load <4 x float>, <4 x float>* %6, align 4, !tbaa !13, !alias.scope !15
  %7 = getelementptr inbounds float, float* %1, i64 %index
  %8 = bitcast float* %7 to <4 x float>*
  %wide.load25 = load <4 x float>, <4 x float>* %8, align 4, !tbaa !13, !alias.scope !18
  %9 = getelementptr inbounds float, float* %7, i64 4
  %10 = bitcast float* %9 to <4 x float>*
  %wide.load26 = load <4 x float>, <4 x float>* %10, align 4, !tbaa !13, !alias.scope !18
  %11 = fadd <4 x float> %wide.load, %wide.load25
  %12 = fadd <4 x float> %wide.load24, %wide.load26
  %13 = getelementptr inbounds float, float* %2, i64 %index
  %14 = bitcast float* %13 to <4 x float>*
  store <4 x float> %11, <4 x float>* %14, align 4, !tbaa !13, !alias.scope !20, !noalias !22
  %15 = getelementptr inbounds float, float* %13, i64 4
  %16 = bitcast float* %15 to <4 x float>*
  store <4 x float> %12, <4 x float>* %16, align 4, !tbaa !13, !alias.scope !20, !noalias !22
```

Параметры: -O3

```
  %17 = getelementptr inbounds float, float* %0, i64 %index.next
  %18 = bitcast float* %17 to <4 x float>*
  %wide.load.1 = load <4 x float>, <4 x float>* %18, align 4, !tbaa !13, !alias.scope !15
  %19 = getelementptr inbounds float, float* %17, i64 4
  %20 = bitcast float* %19 to <4 x float>*
  %wide.load24.1 = load <4 x float>, <4 x float>* %20, align 4, !tbaa !13, !alias.scope !15
  %21 = getelementptr inbounds float, float* %1, i64 %index.next
  %22 = bitcast float* %21 to <4 x float>*
  %wide.load25.1 = load <4 x float>, <4 x float>* %22, align 4, !tbaa !13, !alias.scope !18
  %23 = getelementptr inbounds float, float* %21, i64 4
  %24 = bitcast float* %23 to <4 x float>*
  %wide.load26.1 = load <4 x float>, <4 x float>* %24, align 4, !tbaa !13, !alias.scope !18
  %25 = fadd <4 x float> %wide.load.1, %wide.load25.1
  %26 = fadd <4 x float> %wide.load24.1, %wide.load26.1
  %27 = getelementptr inbounds float, float* %2, i64 %index.next
  %28 = bitcast float* %27 to <4 x float>*
  store <4 x float> %25, <4 x float>* %28, align 4, !tbaa !13, !alias.scope !20, !noalias !22
  %29 = getelementptr inbounds float, float* %27, i64 4
  %30 = bitcast float* %29 to <4 x float>*
  store <4 x float> %26, <4 x float>* %30, align 4, !tbaa !13, !alias.scope !20, !noalias !22
```

- *В целях улучшения читаемости вспомогательные инструкции были удалены из листингов*

Измерение времени исполнения

- benchmark_app/main.cpp
  - Приложения для измерения времени исполнения
- Запуск
  - ./clang –O3 ./benchmark_app/main.cpp -I ./loops/vectorizable/ -DINCLUDE_TEST=\"test**N**.hpp\" -o ./benchmark_app.exe
    - Где **N –** номер вашего варианта
  - ./benchmark_app.exe

- Пример вывода:

Test-1 duration = 55.407 ms

Test-2 duration = 54.482 ms

Test-3 duration = 56.467 ms

Test-4 duration = 59.506 ms

Test-5 duration = 58.993 ms

Test-6 duration = 56.75 ms

Test-7 duration = 56.647 ms

Test-8 duration = 64.19 ms

Test-9 duration = 61.116 ms

Test-10 duration = 61.616 ms

average duration = 58.5174 ms

Выводы

- Необходимо заполнить секции
  - Анализ автоматически векторизованного LLVM IR
  - Анализ времени исполнения автоматически векторизованного кода

Опциональные задачи

- Дополнительно взять для анализа один из циклов содержащихся в папке not_vectorizable
  - Требуется внести правки реализацию цикла чтобы компилятор мог его векторизовать
- Поизучать сгенерированный ассемблер, используя различные векторные расшерения
  - -msse, -msse2, -msse3, -msse4.1, -msse4.2, -mavx, -mavx2, -mavx512f
- Желающие так же могут
  - Выполнить отчёт в формате Markdown/latex/etc
  - Выполнить отчёт на английском языке

Полезные ссылки

- Goldbolt
- LLVM auto vectorization guide
- Intel Intrinsics Guide
- Interleaving and unrolling
- LLVM Language Reference Manual

Вопросы